



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное
учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ
КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

**РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ
ЗАПИСКА**
К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ
НА ТЕМУ:

***Предсказание рейтинга аниме по
жанровым и производственным
характеристикам***

Студент	<u>ИУ5-61Б</u>	<u></u>	<u>Богуславский А.В.</u>
	(группа)	(подпись, дата)	(И.О. Фамилия)
Руководитель НИР		<u></u>	<u>Гапанюк Ю.Е.</u>
		(подпись, дата)	(И.О. Фамилия)

2026 г.

**Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)**

УТВЕРЖДАЮ

Заведующий кафедрой ИУ5
(индекс)

В.И. Терехов
(И.О. Фамилия)

(подпись)

(дата)

З А Д А Н И Е
на выполнение научно-исследовательской работы

по теме Предсказание рейтинга аниме по жанровым и производственным
характеристикам

Студент группы ИУ5-61Б Богуславский Андрей Владимирович
(Фамилия, имя, отчество)

Направленность НИР (учебная, исследовательская, практическая, производственная, др.)
ИССЛЕДОВАТЕЛЬСКАЯ

Источник тематики (кафедра, предприятие, НИР) КАФЕДРА

График выполнения НИР:
25% к _____ нед., 50% к _____ нед., 75% к _____ нед., 100% к _____ нед
Техническое задание: решение задачи машинного обучения на основе материалов
дисциплины

Оформление научно-исследовательской работы: _____
Расчетно-пояснительная записка на 17 листах формата А4.
Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)

Дата выдачи задания « ____ » _____ 202 ____ г.

Студент _____ Богуславский А.В.
(подпись, дата) (И.О. Фамилия)

Руководитель НИР _____ Гапанюк Ю.Е.
(подпись, дата) (И.О. Фамилия)

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	4
1. ПОИСК И ВЫБОР НАБОРА ДАННЫХ	4
2. ЗАГРУЗКА И ПЕРВИЧНЫЙ АНАЛИЗ ДАННЫХ	6
3. РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ (EDA)	7
4. ПРЕДОБРАБОТКА И КОНСТРУИРОВАНИЕ ПРИЗНАКОВ	9
5. КОРРЕЛЯЦИОННЫЙ АНАЛИЗ	10
6. ВЫБОР МЕТРИК ОЦЕНКИ КАЧЕСТВА	11
7. ФОРМИРОВАНИЕ ОБУЧАЮЩЕЙ И ТЕСТОВОЙ ВЫБОРОК	12
8. БАЗОВЫЕ МОДЕЛИ (BASELINE)	12
9. ПОДБОР ГИПЕРПАРАМЕТРОВ (GRIDSEARCHCV)	13
10. СРАВНЕНИЕ МОДЕЛЕЙ	14
11. АНАЛИЗ ЛУЧШЕЙ МОДЕЛИ	15
ЗАКЛЮЧЕНИЕ	18
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	19

ВВЕДЕНИЕ

Задача автоматической оценки качества медиаконтента по его характеристикам является актуальным направлением в области анализа данных и машинного обучения. Аниме-индустрия ежегодно производит сотни тайтлов, а агрегированные пользовательские оценки на платформах MyAnimeList являются важным индикатором популярности и качества произведения. Автоматическое предсказание оценки до её формирования сообществом позволяет студиям, дистрибьюторам и стриминговым сервисам принимать более обоснованные решения.

В рамках данной научно-исследовательской работы реализована система регрессии для предсказания пользовательской оценки аниме (score) на платформе MyAnimeList на основе параметров тайтла. Для построения моделей использованы как простые алгоритмы (Ridge-регрессия, KNN, Decision Tree), так и ансамблевые методы (Random Forest, Gradient Boosting).

Целью работы является построение регрессионной модели машинного обучения, обеспечивающей максимальное качество предсказания оценки аниме. В процессе работы выполнен полный цикл: поиск и анализ данных, разведочный анализ, предобработка и конструирование признаков, корреляционный анализ, обучение и сравнение моделей, подбор гиперпараметров.

1. ПОИСК И ВЫБОР НАБОРА ДАННЫХ

Для решения задачи был выбран датасет «Anime Dataset» (Kaggle), содержащий информацию о более чем 30 000 аниме-тайтлов. Датасет охватывает широкий спектр характеристик: тип выпуска, жанры, возрастной рейтинг, количество серий, длительность, количество участников и избранных пользователей.

Обоснование выбора датасета:

- полнота — 30 075 записей с разнообразными характеристиками тайтлов;
- многомерность — 29 признаков из различных областей: тип, жанр, рейтинг, популярность;
- наличие пропусков — датасет реалистичен и требует применения методов обработки пропущенных значений;
- наличие как числовых, так и категориальных признаков, что требует полного цикла предобработки;

- чёткая непрерывная целевая переменная — оценка аниме (score) в диапазоне от 1 до 10.

Практическая значимость. Построенная модель демонстрирует, что оценка аниме тесно связана с его параметрами популярности (количество участников и избранных) и характеристиками контента (тип, рейтинг, жанр). Подобные модели применяются стриминговыми сервисами для рекомендательных систем и прогнозирования коммерческого успеха тайтла.

Целевая переменная — оценка аниме (score) — представляет собой среднее значение оценок всех пользователей MyAnimeList. Перечень основных признаков датасета приведён в таблице 1.1.

Таблица 1.1 — Описание признаков датасета

Признак	Тип	Описание
title_japanese	строка	Оригинальное название аниме на японском
type	категориальный	Тип тайтла (TV, Movie, OVA, ONA, Special, Music)
episodes	числовой	Количество серий
status	категориальный	Статус выхода (Finished, Airing, Not yet aired)
aired_from	дата	Дата начала выхода
rating	категориальный	Возрастной рейтинг (G, PG, PG-13, R-17+, R+, Rx)
genres	строка	Жанры аниме (многозначный атрибут)
source	категориальный	Источник (Manga, Original, Light novel, и др.)
members	числовой	Количество пользователей, добавивших в список
favorites	числовой	Количество пользователей, добавивших в избранное
score	числовой	Средняя оценка пользователей — целевая переменная
rank	числовой	Глобальный рейтинг аниме
scored_by	числовой	Количество пользователей, поставивших оценку

2. ЗАГРУЗКА И ПЕРВИЧНЫЙ АНАЛИЗ ДАННЫХ

Загрузка данных выполнена с помощью библиотеки pandas. При первичном осмотре датасета (30 075 строк, 29 столбцов) обнаружено следующее:

- числовые признаки members и favorites имеют сильно скошенное распределение (тяжёлый правый хвост) — требуется логарифмическое преобразование;

- пропущенные значения присутствуют в ряде признаков: score — ~15 %, licensors — ~78 %, season — ~77 %, demographics — ~73 %;
- признак genres хранится в виде строки со списком жанров — требуется создание бинарных признаков (one-hot encoding);
- признак duration хранится в текстовом формате вида «23 min per ep» — требуется парсинг в числовое значение (минуты);
- целевая переменная score имеет нормальное распределение с центром около 6.5 балла, что благоприятно для задачи регрессии.

Итоговый размер датасета после удаления записей без оценки: 24 823 строки × 29 признаков. После конструирования признаков итоговый набор составил 17 числовых переменных.

3. РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ (EDA)

Для понимания структуры данных и зависимостей между признаками проведён разведочный анализ, включающий построение гистограмм, ящичных диаграмм, диаграмм рассеяния и диаграмм распределения пропусков.

На рисунке 1 представлен комплексный разведочный анализ датасета. В левом верхнем углу показано распределение целевой переменной (оценки). Распределение близко к нормальному с центром около 6.5 балла, что свидетельствует об отсутствии значительного смещения и пригодности данных для регрессионного анализа.

Ящичные диаграммы демонстрируют распределение оценок по типам аниме и возрастным рейтингам. TV-сериалы и Movie имеют наиболее широкий диапазон оценок. Тайтлы с рейтингом R-17+ (violence & profanity) систематически получают более высокие оценки по сравнению с контентом для детей.

Диаграмма рассеяния log(members) vs Score выявляет чёткую положительную зависимость: аниме с большим числом участников в среднем получает более высокую оценку, хотя разброс значителен. Это указывает на нелинейную зависимость, которую линейные модели могут не уловить в полной мере.

Столбчатые диаграммы показывают топ-12 жанров по частоте встречаемости и долю пропущенных значений по признакам. Comedy является наиболее распространённым жанром (более 8 000 тайтлов), за ним следуют Fantasy и Action. Признаки licensors и season имеют долю пропусков более 75 % и исключены из анализа.




Рисунок 1 – Разведочный анализ данных (EDA): распределение оценок, зависимости по типам и рейтингам, топ жанров, пропуски

4. ПРЕДОБРАБОТКА И КОНСТРУИРОВАНИЕ ПРИЗНАКОВ

По результатам EDA выполнены следующие шаги предобработки:

- удаление строк без значения целевой переменной score (исходно ~15 % пропусков);
- парсинг длительности: текстовый формат «23 min per ep» преобразован в числовое значение в минутах (duration_min) с помощью регулярных выражений;
- логарифмическое преобразование сильно скошенных признаков: $\log_members = \log(members + 1)$, $\log_favorites = \log(favorites + 1)$;
- кодирование типа аниме (type_enc) с помощью ручного маппинга: TV=0, Movie=1, OVA=2, ONA=3, Special=4, Music=6;
- кодирование возрастного рейтинга (rating_enc) в порядковую шкалу: G=0, PG=1, PG-13=2, R-17+=3, R+=4, Rx=5;
- кодирование источника (source_enc) с помощью LabelEncoder;
- кодирование статуса (status_enc) с помощью LabelEncoder;

- one-hot encoding топ-8 жанров: genre_Comedy, genre_Action, genre_Fantasy, genre_Adventure, genre_Drama, genre_Sci-Fi, genre_Romance, genre_Slice_of_Life;
- заполнение пропущенных значений числовых признаков медианой по соответствующим группам.

Итоговый набор признаков для модели составил 17 числовых переменных.

Масштабирование StandardScaler применено к моделям, чувствительным к масштабу (Ridge, KNN).

5. КОРРЕЛЯЦИОННЫЙ АНАЛИЗ

Корреляционный анализ проведён для оценки линейных зависимостей между признаками и целевой переменной. На рисунке 2 представлена матрица корреляций Пирсона и столбчатая диаграмма корреляций с целевой переменной score.




Рисунок 2 – Матрица корреляций признаков и корреляция с целевой переменной (score)

Выявлены следующие значимые зависимости:

- log_favorites и score: $r \approx +0.68$ — наибольшая положительная корреляция; количество пользователей, добавивших аниме в избранное, является сильнейшим предиктором оценки;
- log_members и score: $r \approx +0.65$ — высокая положительная корреляция; популярность тайтла тесно связана с его оценкой;
- duration_min и score: $r \approx +0.32$ — умеренная положительная зависимость; более длинные эпизоды в среднем оцениваются выше;
- type_enc и score: $r \approx -0.25$ — отрицательная зависимость; TV-сериалы (код 0) в среднем оцениваются ниже, чем фильмы;
- log_members и log_favorites: $r \approx +0.89$ — высокая взаимная корреляция, что свидетельствует о мультиколлинеарности данных признаков.

Высокая взаимная корреляция между `log_members` и `log_favorites` не влияет на ансамблевые методы, однако может снижать стабильность линейных моделей. Корреляционный анализ подтверждает, что популярность аниме является основным фактором его оценки, а характеристики контента (жанр, рейтинг) вносят вторичный вклад.

6. ВЫБОР МЕТРИК ОЦЕНКИ КАЧЕСТВА

Для оценки качества регрессионных моделей выбраны три метрики (таблица 6.1). Выбор определяется интерпретируемостью в единицах шкалы оценок (от 1 до 10 баллов) и необходимостью штрафовать за крупные ошибки.

Таблица 6.1 — Метрики оценки качества регрессии

Метрика	Формула	Обоснование выбора
RMSE	$\sqrt{(\sum (y_i - \hat{y}_i)^2 / n)}$	Штрафует за крупные ошибки сильнее MAE. Полезен, когда отклонение на 2+ балла критично.
MAE	$\sum y_i - \hat{y}_i / n$	Средняя абсолютная ошибка в баллах. Устойчив к выбросам. Прямая интерпретация.
R ²	$1 - SS_{res} / SS_{tot}$	Доля объяснённой дисперсии. R ² =1 — идеал, R ² =0 — модель не лучше среднего.

RMSE является основной метрикой: ошибка в 0.5 балла приемлема, тогда как ошибка в 2 балла существенно снижает ценность предсказания. MAE обеспечивает дополнительный устойчивый к выбросам контроль, а R² даёт общее представление о качестве модели относительно тривиального предсказания среднего значения.

7. ФОРМИРОВАНИЕ ОБУЧАЮЩЕЙ И ТЕСТОВОЙ ВЫБОРОК

Датасет разбит на обучающую и тестовую выборки в соотношении 80/20 с помощью функции `train_test_split` библиотеки `scikit-learn`. Параметр `random_state=42` зафиксирован для обеспечения воспроизводимости результатов (таблица 7.1).

Таблица 7.1 — Разбивка данных на выборки

Выборка	Назначение	Размер (записей)
Обучающая	Обучение моделей и подбор гиперпараметров	19 858
Тестовая	Финальная оценка качества моделей	4 965

Масштабирование `StandardScaler` обучалось только на обучающей выборке для предотвращения утечки данных (`data leakage`). Трансформация применялась к признакам, не к целевой переменной.

8. БАЗОВЫЕ МОДЕЛИ (BASELINE)

На первом этапе обучены пять моделей с параметрами по умолчанию (baseline). Из них две — ансамблевые: Random Forest (бэггинг) и Gradient Boosting (бустинг). Результаты приведены в таблице 8.1.

Таблица 8.1 — Результаты базовых моделей на тестовой выборке

Модель	RMSE	MAE	R ²
Ridge	0.604	0.463	0.541
KNN	0.560	0.410	0.606
Decision Tree	0.700	0.503	0.382
Random Forest *	0.508	0.370	0.675
Gradient Boosting *	0.530	0.392	0.648

* — ансамблевые методы

Лучший результат среди базовых моделей показал Random Forest: RMSE = 0.508, R² = 0.675. Это свидетельствует о том, что ансамблевые методы лучше справляются с нелинейными зависимостями в данных. Decision Tree показал наихудший результат (R² = 0.382), что объясняется переобучением модели без ограничений глубины.

9. ПОДБОР ГИПЕРПАРАМЕТРОВ (GRIDSEARCHCV)

Для всех пяти моделей выполнен перебор гиперпараметров методом GridSearchCV с 5-кратной кросс-валидацией и метрикой `neg_mean_squared_error`. Оптимальные значения параметров приведены в таблице 9.1.

Таблица 9.1 — Оптимальные гиперпараметры по результатам GridSearchCV

Модель	Параметр	Оптимальное значение
Ridge	alpha	alpha=1.0
KNN	n_neighbors	n_neighbors=10
Decision Tree	max_depth, min_samples_split	max_depth=7, min_samples_split=10
Random Forest	n_estimators, max_depth	n_estimators=200, max_depth=20
Gradient Boosting	n_estimators, learning_rate, max_depth	n_estimators=200, learning_rate=0.1, max_depth=5

На рисунке 3 показано влияние ключевых гиперпараметров на качество моделей по метрике CV RMSE. Для KNN оптимальное число соседей составило n=10: при меньших значениях модель переобучается, при больших — недообучается. Для Random Forest увеличение числа деревьев с 100 до 200 незначительно улучшает качество;

глубина `max_depth=20` оказалась оптимальной. Для Gradient Boosting наилучший результат достигается при `learning_rate=0.1` и `max_depth=5`.




Рисунок 3 – Влияние гиперпараметров на качество (CV RMSE)

10. СРАВНЕНИЕ МОДЕЛЕЙ

В таблице 10.1 приведены метрики качества настроенных моделей в сравнении с базовыми.

Таблица 10.1 — Сравнение Baseline и оптимизированных моделей

Модель	Версия	RMSE	MAE	R ²
Ridge	Baseline	0.604	0.463	0.541
Ridge	Tuned	0.601	0.461	0.542
KNN	Baseline	0.560	0.410	0.606
KNN	Tuned	0.555	0.408	0.619
Decision Tree	Baseline	0.700	0.503	0.382
Decision Tree	Tuned	0.568	0.417	0.599
Random Forest *	Baseline	0.508	0.370	0.675
Random Forest *	Tuned	0.504	0.369	0.681
Gradient Boosting *	Baseline	0.530	0.392	0.648
Gradient Boosting *	Tuned	0.495	0.366	0.691

* — ансамблевые методы

Подбор гиперпараметров значительно улучшил Decision Tree (RMSE снизился с 0.700 до 0.568, прирост R² на +0.217), а также дал умеренное улучшение для Gradient Boosting (RMSE: 0.530 → 0.495). Для Ridge и KNN улучшение минимально, что объясняется малым пространством поиска гиперпараметров.

На рисунке 4 наглядно показано преимущество ансамблевых методов перед простыми алгоритмами по всем трём метрикам. Gradient Boosting (tuned) демонстрирует лучшее качество по всем показателям.




Рисунок 4 – Сравнение моделей: Baseline vs Оптимизированные (RMSE, MAE, R^2)

11. АНАЛИЗ ЛУЧШЕЙ МОДЕЛИ

Лучшей моделью по совокупности метрик признан Gradient Boosting с параметрами $n_estimators=200$, $learning_rate=0.1$, $max_depth=5$. Итоговые метрики на тестовой выборке: $RMSE = 0.495$, $MAE = 0.366$, $R^2 = 0.691$.

Это означает, что модель в среднем ошибается на 0.37 балла, а 69.1 % дисперсии оценок объясняется предложенными признаками. Для шкалы оценок от 1 до 10 это достаточно высокий результат, учитывая субъективную природу пользовательских оценок.

На рисунке 5 показан анализ предсказаний лучшей модели. Диаграмма рассеяния «Предсказанные vs Фактические» демонстрирует хорошую линейную зависимость вдоль идеальной диагонали. Распределение остатков близко к нормальному с центром в нуле — признак качественной спецификации модели.




Рисунок 5 – Gradient Boosting: диаграмма предсказанные vs фактические и распределение остатков

Незначительная асимметрия распределения остатков в сторону отрицательных значений указывает на то, что модель несколько занижает оценки для тайтлов с очень высокими оценками (8–9 баллов). Это ожидаемое явление для регрессии при работе с экстремальными значениями.

На рисунке 6 показана важность признаков для модели Random Forest (tuned). Наиболее значимые признаки:

- `log_favorites` — логарифм числа добавлений в избранное (~53 %): наиболее мощный предиктор оценки; аниме, вызывающее сильную эмоциональную реакцию, получает высокие оценки;
- `log_members` — логарифм числа участников (~12 %): общая популярность тайтла коррелирует с его качеством;
- `duration_min` — длительность эпизода в минутах (~9 %): более длинные форматы (полнометражные фильмы, OVA) получают более высокие оценки;
- `rating_enc` — возрастной рейтинг (~6 %): контент для взрослой аудитории систематически оценивается выше;
- `episodes_fill` — количество серий (~4 %): длинные сериалы накапливают лояльную аудиторию;
- `source_enc` и `type_enc` (~3–4 % каждый): источник адаптации и тип тайтла вносят значимый вклад;
- жанровые признаки (`genre_*`) — по ~1 % каждый: вклад отдельных жанров минимален, что объясняется их бинарной природой.




Рисунок 6 – Важность признаков (Random Forest, Tuned)

Доминирование признаков популярности (`log_favorites`, `log_members`) над признаками контента подтверждает гипотезу о том, что оценки на MyAnimeList в значительной мере определяются не объективными характеристиками аниме, а его популярностью в сообществе. Это создаёт проблему циркулярной причинности: популярные тайтлы получают больше оценок, что повышает их средний балл за счёт регрессии к среднему.

ЗАКЛЮЧЕНИЕ

В ходе работы решена задача регрессии — предсказание пользовательской оценки аниме по параметрам тайтла на основе датасета с 30 075 записями.

Сформулируем основные выводы.

- Датасет Anime Dataset оказался информативным и пригодным для задачи регрессии. После очистки и конструирования признаков итоговый набор составил 17 числовых переменных, разбитых на обучающую (19 858 записей) и тестовую (4 965 записей) выборки.
- Разведочный анализ показал, что распределение оценок близко к нормальному. Наибольшую предсказательную силу имеют признаки популярности: `log_favorites` и `log_members`. Жанровые признаки и тип аниме оказывают вторичный эффект.

- Корреляционный анализ выявил сильную линейную зависимость $\log_favorites \rightarrow score$ ($r \approx 0.68$) и $\log_members \rightarrow score$ ($r \approx 0.65$), а также высокую взаимную корреляцию между ними ($r \approx 0.89$).
- Из пяти протестированных алгоритмов ансамблевые методы значительно превосходили простые. Базовый Random Forest уже достиг $RMSE = 0.508$, $R^2 = 0.675$.
- Подбор гиперпараметров методом GridSearchCV (5-кратная кросс-валидация) значительно улучшил Decision Tree и Gradient Boosting. Для Ridge и KNN улучшение оказалось минимальным.
- Лучшей моделью стал Gradient Boosting (tuned): $RMSE = 0.495$, $MAE = 0.366$, $R^2 = 0.691$. Модель в среднем ошибается на 0.37 балла по 10-балльной шкале.
- Анализ важности признаков показал доминирование $\log_favorites$ (~53 %) и $\log_members$ (~12 %), что свидетельствует о тесной связи между популярностью аниме и его рейтингом в сообществе MyAnimeList.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Anime Dataset [Электронный ресурс] // Kaggle. — URL: <https://www.kaggle.com/datasets/dbdmobile/myanimelist-dataset> (дата обращения: 20.05.2026).
2. Pedregosa F. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830. — URL: <https://scikit-learn.org> (дата обращения: 20.05.2026).
3. Breiman L. Random Forests // Machine Learning. — 2001. — Vol. 45, № 1. — P. 5–32.
4. Friedman J.H. Greedy Function Approximation: A Gradient Boosting Machine // The Annals of Statistics. — 2001. — Vol. 29, № 5. — P. 1189–1232.
5. Pandas — документация [Электронный ресурс]. — URL: <https://pandas.pydata.org/docs> (дата обращения: 20.05.2026).
6. Müller A.C., Guido S. Introduction to Machine Learning with Python. — O'Reilly Media, 2016. — 400 p.
7. MyAnimeList — официальный сайт [Электронный ресурс]. — URL: <https://myanimelist.net> (дата обращения: 20.05.2026).